

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación
CC3084 – Data Science
Ing. Mario Barrientos



Laboratorio V: Clasificación de tweets usando minería de texto y análisis de sentimiento

José Donado
Daniela Ramírez
Cindy Gualim

Guatemala, 30 de agosto de 2026

Resumen

Se construyó un clasificador capaz de distinguir si un tweet habla de un desastre real o no, usando el conjunto de datos Natural Language Processing with Disaster Tweets de Kaggle (7,613 tweets etiquetados). El texto se limpió y se representó con TF-IDF de unigramas y bigramas, y sobre esa representación se compararon tres algoritmos. La Regresión Logística fue el mejor modelo, con 81.5 % de accuracy y 0.812 de F1 ponderado en el conjunto de prueba. Con ese modelo se elaboró una función que recibe un tweet sin preprocesar y devuelve la clasificación junto con su nivel de confianza. Además se hizo un análisis de sentimiento con TextBlob: los tweets de desastres reales resultaron estadísticamente menos positivos que los demás (polaridad media de 0.019 frente a 0.071, prueba de Mann-Whitney con $p < 0.001$), pero la diferencia es pequeña. Al agregar una variable de "negatividad" al modelo, el desempeño no mejoró: el F1 bajó de 0.8122 a 0.8095.

Objetivo y metodología

El objetivo fue clasificar automáticamente tweets según se refieran o no a un desastre real, y evaluar si la carga emocional del texto aporta información útil para esa clasificación. El conjunto de datos tiene 7,613 filas y 5 columnas (id, keyword, location, text y target). La variable keyword tiene apenas 0.8 % de valores faltantes, pero location falta en el 33.3 % de los registros, por lo que no se usó como predictor. La distribución de clases está moderadamente desbalanceada: 4,342 tweets no son desastres (57 %) y 3,271 sí lo son (43 %).

Limpieza y preprocesamiento

El preprocesamiento se hizo con NLTK y expresiones regulares, en el siguiente orden: conversión a minúsculas, eliminación de URLs, eliminación de menciones de usuario (@), eliminación de emoticones de texto, eliminación de signos de puntuación y de números, normalización de espacios, tokenización, remoción de stopwords en inglés y lematización con WordNetLemmatizer.

Dos decisiones merecen explicarse porque cambiaron el resultado. En una primera versión se eliminaban también los hashtags completos, pero eso destruía el contenido del tweet: el tweet "Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all" quedaba como "deed reason may allah forgive u", perdiendo justamente la palabra que indica el desastre. Por eso se decidió borrar únicamente el símbolo "#" y conservar la palabra, ya que el hashtag suele ser el tema central del tweet. La segunda decisión fue conservar el número 911, que se refiere al número de emergencias y sí es informativo, mientras que el resto de números se eliminó.

Representación del texto y validación

Para representar los tweets se usó TF-IDF con unigramas y bigramas (ngram_range=(1,2)), un máximo de 5,000 características y min_df=2, de modo que se descartan los términos que aparecen una sola vez en todo el corpus. Los datos se dividieron en 80 % para entrenamiento (6,090 tweets) y 20 % para prueba (1,523 tweets), manteniendo la proporción de clases mediante muestreo estratificado y con semilla fija para que el experimento sea reproducible.

Análisis exploratorio

Al separar el corpus por categoría y contar las palabras, la más frecuente en los tweets de desastres reales es "fire" (263 apariciones) y en los que no son desastres es "like" (255 apariciones). La Tabla 1 muestra las diez palabras más frecuentes de cada categoría.

Desastres reales	Frecuencia	No desastres	Frecuencia
fire	263	like	255
news	138	im	243
via	121	amp	193
disaster	118	get	185
california	115	new	168
suicide	110	u	146
police	107	dont	141
amp	106	one	136
people	106	body	116
family	105	time	102

Tabla 1. Diez palabras más frecuentes en cada categoría, después del preprocesamiento.

El contraste es claro. En los tweets de desastres aparecen sustantivos concretos ligados a eventos —fire, disaster, california, suicide, police, family—, mientras que en los no desastres dominan muletillas del lenguaje coloquial de Twitter —like, im, get, dont, one—. Vale la pena notar que "amp" es un residuo del código HTML "&" y que "u" viene de la lematización de "us"; ninguna de las dos aporta significado, pero se dejaron porque no distorsionan el modelo. Las nubes de palabras de la Figura 1 y el histograma de la Figura 2 muestran visualmente esta misma diferencia.



Figura 1. Nubes de palabras por categoría: desastres reales (izquierda) y no desastres (derecha).




Figura 2. Quince palabras más frecuentes en cada categoría.

El vocabulario de ambas categorías se traslapa bastante: hay 7,620 palabras distintas en los tweets de desastres, 9,796 en los de no desastres, y 3,598 aparecen en ambos grupos. Esto era esperable porque el vocabulario general de Twitter es compartido. Lo importante, entonces, no es que una palabra aparezca en las dos categorías sino qué tan desbalanceada está su frecuencia. La palabra "fire" aparece 263 veces en desastres y solo 88 en no desastres; "killed" aparece 93 veces contra 3; "california" 115 contra 6. En cambio "amp" (106 contra 193) o "people" (106 contra 92) están repartidas de forma pareja y no ayudan a decidir. Por eso se eligió TF-IDF en lugar de un simple conteo: TF-IDF penaliza automáticamente los términos que aparecen en muchos documentos y le da más peso a los que son distintivos.

Bigramas y trigramas

Para capturar el contexto y no solo palabras sueltas se generaron bigramas y trigramas por categoría, con su frecuencia y su probabilidad relativa dentro del conjunto de n-gramas de esa categoría. La Tabla 2 resume los resultados más representativos.

N-grama	Frecuencia	Probabilidad	Categoría
suicide bomber	60	0.00220	Desastre real
northern california	41	0.00150	Desastre real
oil spill	38	0.00139	Desastre real
california wildfire	36	0.00132	Desastre real
burning building	35	0.00128	Desastre real
body bag	46	0.00142	No desastre
cross body	38	0.00118	No desastre
liked video	34	0.00105	No desastre
look like	32	0.00099	No desastre

N-grama	Frecuencia	Probabilidad	Categoría
suicide bomber detonated	30	0.00125	Desastre real (trigrama)
northern california wildfire	29	0.00121	Desastre real (trigrama)
cross body bag	22	0.00079	No desastre (trigrama)

Tabla 2. Bigramas y trigramas más frecuentes por categoría, con su probabilidad relativa.

Los bigramas sí aportan contexto que las palabras aisladas no capturan: "suicide bomber", "oil spill" o "california wildfire" identifican un evento real con mucha más precisión que sus palabras por separado. Un caso interesante es "body bag" (bolsa para cadáveres), que aparece con frecuencia alta en la categoría de no desastres porque en realidad forma parte de "cross body bag", un tipo de bolso; el trigrama lo aclara. Los trigramas, sin embargo, se fragmentan demasiado: sus frecuencias son bajas y muchos corresponden a un solo tweet replicado varias veces, así que memorizan casos particulares en lugar de generalizar. Por eso se incluyeron unigramas y bigramas en el TF-IDF y se descartaron los trigramas, para evitar sobreajuste.

Modelos de clasificación

Sobre la matriz TF-IDF se entrenaron tres algoritmos con el mismo conjunto de entrenamiento: Naive Bayes Multinomial (parámetros por defecto), Random Forest (200 árboles, sin límite de profundidad) y Regresión Logística (máximo 1,000 iteraciones). Los tres se evaluaron sobre el mismo conjunto de prueba de 1,523 tweets con accuracy, precision, recall y F1 ponderados. La Tabla 3 y la Figura 3 resumen los resultados.

Modelo	Accuracy	Precision	Recall	F1
Regresión Logística	0.8148	0.8170	0.8148	0.8122
Naive Bayes	0.8129	0.8215	0.8129	0.8080
Random Forest	0.7951	0.7946	0.7951	0.7937

Tabla 3. Comparación de los tres modelos sobre el conjunto de prueba (métricas ponderadas).




Figura 3. Comparación de métricas entre los tres algoritmos evaluados.

La Regresión Logística obtuvo el mejor F1 (0.8122) y la mejor accuracy (81.5 %), seguida muy de cerca por Naive Bayes, mientras que Random Forest quedó unos dos puntos por debajo. Esta diferencia tiene una explicación razonable: la matriz TF-IDF tiene 5,000 columnas y es muy dispersa, es decir, casi todas sus entradas son cero porque cada tweet usa apenas unas cuantas palabras del vocabulario total. En ese escenario los modelos lineales generalizan mejor, porque combinan la evidencia de muchas palabras a la vez, mientras que los árboles del Random Forest tienen que elegir variables una por una y terminan sobreajustándose a términos poco informativos.

Vale la pena mirar el detalle por clase y no solo el promedio. La Regresión Logística alcanza 0.90 de recall en la clase "no desastre" pero solo 0.71 en la clase "desastre", lo que significa que casi tres de cada diez desastres reales se le escapan. Para este problema ese es el error más costoso, porque decir que un tweet no habla de un desastre cuando sí lo hace equivale a no levantar una alerta que era necesaria. El desbalance de clases explica parte de este comportamiento: el modelo tiende a favorecer la clase mayoritaria. Aun así, la Regresión Logística se seleccionó como mejor modelo por tener el F1 más alto, y es la que se usa en la función de clasificación.

Función de clasificación

Se elaboró la función `clasificar_tweet`, que recibe el texto de un tweet sin preprocesar y devuelve si se trata de un desastre real o no. Internamente reutiliza exactamente el mismo pipeline con el que se entrenó el modelo: aplica la función de limpieza, transforma el texto con el mismo objeto TF-IDF ya ajustado (sin volver a ajustarlo, para no filtrar información del conjunto de prueba) y predice con la Regresión Logística. Además de la etiqueta devuelve el nivel de confianza, obtenido de la probabilidad que asigna el modelo. La Tabla 4 muestra los resultados con tweets de prueba escritos a propósito para poner a prueba la ambigüedad del lenguaje.

Tweet de entrada	Clasificación	Confianza
Massive earthquake hits California, thousands evacuated from their homes #earthquake	Desastre real	93.4 %
I'm on fire today, just crushed my workout at the gym!!	No es desastre	70.8 %
BREAKING: Wildfire spreading fast near the highway, residents told to evacuate immediately	Desastre real	87.5 %
This new song is absolute fire, can't stop listening to it	No es desastre	82.7 %
Explosion reported at a chemical plant, emergency services on the scene	Desastre real	61.3 %
lol my little brother just exploded with laughter watching that movie	No es desastre	82.2 %

Tabla 4. Resultados de la función de clasificación con tweets sin preprocesar.

La función acierta en los seis casos, incluidos los pares diseñados para confundirla. Distingue "fire" usado literalmente ("Wildfire spreading fast") de su uso coloquial ("this song is absolute fire"), y "explode" como evento real frente a "exploded with laughter". Esto confirma que los bigramas del TF-IDF sí están aportando contexto más allá de la palabra aislada. También es útil observar la confianza: el caso de la planta química obtiene apenas 61.3 %, bastante menos que los otros, lo cual es razonable porque es el tweet con vocabulario menos frecuente en el corpus de entrenamiento.

Análisis de sentimiento

Para el análisis de sentimiento se usó TextBlob, que asigna a cada texto una polaridad entre -1 (muy negativo) y +1 (muy positivo) y permite recuperar las expresiones concretas a las que atribuye carga emocional. Una decisión importante fue aplicarlo sobre el texto original y no sobre el texto limpio, porque la limpieza elimina puntuación y emoticones que sí llevan información emocional; el emoticón ";(", por ejemplo, se pierde por completo tras el preprocesamiento. Se clasificó cada tweet como positivo si su polaridad supera 0.05, negativo si es menor a -0.05 y neutral en el resto de los casos.

De los 7,613 tweets, 3,880 resultaron neutrales (51 %), 2,310 positivos (30 %) y 1,423 negativos (19 %). La mayoría neutral se explica porque muchos tweets de desastres son en realidad titulares de noticias, escritos en un tono informativo y sin palabras emocionales. La Tabla 5 cruza el sentimiento con la categoría real.

Sentimiento	No desastre	Desastre real	Diferencia
Negativo	17.39 %	20.42 %	+3.03
Neutral	48.60 %	54.11 %	+5.51
Positivo	34.02 %	25.47 %	-8.55

Tabla 5. Distribución porcentual del sentimiento dentro de cada categoría.




Figura 4. Sentimiento de los tweets según su categoría real.

El resultado es menos intuitivo de lo esperado. Los tweets de desastres no son mucho más negativos: la diferencia en la proporción de tweets negativos es de apenas 3 puntos porcentuales. Donde sí hay una diferencia notable es en el extremo positivo: los tweets que no hablan de desastres son positivos con mucha más frecuencia (34.0 % contra 25.5 %). Es decir, el sentimiento separa mejor por ausencia de positividad que por presencia de negatividad, como se ve en la Figura 4.

Los tweets más extremos

Al ordenar por polaridad, los diez tweets más negativos (polaridad = -1.0) son 7 de desastres reales y 3 de no desastres. Cinco de ellos son variantes casi idénticas de una misma noticia sobre un accidente aéreo mortal, lo que muestra que los tweets se replican mucho en este corpus. Los tres que no son desastres deben su polaridad a palabras aisladas como "nasty" o "horrible" usadas en contextos cotidianos.

En el otro extremo, los diez tweets más positivos (polaridad = 1.0) son 9 de no desastres y solo 1 de desastre real. Ese único caso es un tweet que dice "I liked a @YouTube video" y que enlaza a un video sobre un desastre: TextBlob detecta el verbo "liked" como positivo aunque el tema del tweet no lo sea. Esto ilustra una limitación clara del método: al ser un análisis basado en léxico, TextBlob evalúa las palabras individuales y no entiende de qué habla realmente el tweet.

Para responder formalmente si los tweets de desastres son más negativos se compararon las distribuciones de polaridad (Figura 5) y se aplicó la prueba no paramétrica de Mann-Whitney con hipótesis unilateral, apropiada porque la polaridad no sigue una distribución normal y está muy concentrada en cero. La polaridad media de los tweets de desastres reales es 0.0186 frente a 0.0706 de los demás, una diferencia de -0.052; el estadístico U fue 6,305,330 con un valor p menor a 0.001. Existe entonces evidencia estadísticamente significativa de que los tweets de desastres reales tienen menor polaridad, pero conviene ser prudentes al interpretarla: con más de 7,600 observaciones, una prueba estadística detecta diferencias muy pequeñas. La mediana de polaridad es 0 en ambas categorías, y la diferencia de medias es de apenas cinco centésimas en una escala que va de -1 a 1. La diferencia es real, pero pequeña.




Figura 5. Distribución de polaridad y de negatividad según la categoría del tweet.

Variable de negatividad e impacto en el modelo

Se creó la variable negatividad, definida como la proporción de expresiones negativas respecto al total de expresiones con carga emocional que TextBlob detecta en el tweet. Toma valores entre 0 y 1: un tweet con solo expresiones negativas obtiene 1, uno con solo expresiones positivas obtiene 0, y uno con la misma cantidad de ambas obtiene 0.5. Su promedio es 0.2306 en los tweets de desastres y 0.2060 en los demás.

Esta variable se añadió como una columna adicional a la matriz TF-IDF, que pasó de 5,000 a 5,001 columnas, y se volvió a entrenar la Regresión Logística conservando exactamente la misma división de entrenamiento y prueba, para que la comparación fuera justa. La Tabla 6 y la Figura 6 muestran el resultado.

Métrica	Modelo original	Con negatividad	Cambio
Accuracy	0.8148	0.8122	-0.0026
Precision	0.8170	0.8143	-0.0027
Recall	0.8148	0.8122	-0.0026
F1-score	0.8122	0.8095	-0.0027

Tabla 6. Desempeño del modelo antes y después de incluir la variable de negatividad.




Figura 6. Comparación del modelo antes y después de incluir la negatividad.

La inclusión de la variable no mejoró el modelo: todas las métricas bajaron alrededor de 0.27 puntos porcentuales, y el F1 pasó de 0.8122 a 0.8095. El recall de la clase "desastre", que era lo que más interesaba mejorar, bajó de 0.71 a 0.70. Es un cambio pequeño, del orden de cuatro tweets mal clasificados de 1,523, así que en la práctica el modelo es equivalente; pero lo importante es que no hubo ninguna ganancia.

Hay tres razones que explican este resultado. La primera es que el TF-IDF ya incorpora las palabras con carga negativa —killed, suicide, disaster— como variables propias, así que la negatividad no aporta información nueva sino una versión resumida y más pobre de algo que el modelo ya tenía. La segunda es que, como se vio en la Tabla 5, el sentimiento negativo no es exclusivo de los desastres: un tweet puede expresar enojo o tristeza por motivos completamente cotidianos, y la diferencia de negatividad media entre categorías es de apenas 0.025. La tercera es una limitación de cómo se construyó la variable: cuando un tweet no tiene ninguna expresión con carga emocional, la negatividad vale 0, el mismo valor que recibe un tweet claramente positivo. Como el 51 % de los tweets son neutrales, más de la mitad del conjunto queda mezclada con los positivos en el mismo valor, lo que diluye cualquier señal útil que la variable pudiera tener.

Conclusiones

- El mejor modelo fue la Regresión Logística sobre TF-IDF de unigramas y bigramas, con 81.5 % de accuracy y 0.812 de F1 en el conjunto de prueba. Su principal debilidad es el recall de 0.71 en la clase de desastres reales, que es justamente el error más costoso para este problema.
- Las decisiones de preprocesamiento importaron tanto como la elección del algoritmo. Conservar la palabra del hashtag y el número 911 preservó información que la limpieza inicial estaba borrando.

- Los bigramas aportan contexto real y ayudan a desambiguar usos figurados como "this song is fire". Los trigramas, en cambio, tienen frecuencias demasiado bajas para generalizar con este tamaño de corpus.
- Los tweets de desastres reales son estadísticamente menos positivos que los demás ($p < 0.001$), pero la diferencia es pequeña y el sentimiento separa mejor por ausencia de positividad que por presencia de negatividad.
- Agregar la negatividad como variable no mejoró la clasificación; el F1 bajó 0.0027. La información emocional ya estaba contenida en el TF-IDF y la variable, tal como se definió, no distingue entre tweets neutrales y positivos.

Como trabajo futuro, la mejora más prometedora sería atacar directamente el recall de la clase de desastres, ya sea ajustando el umbral de decisión o usando pesos balanceados por clase. También convendría redefinir la variable de negatividad para que separe los tweets sin carga emocional de los positivos, o sustituir TextBlob por un modelo de sentimiento entrenado específicamente para lenguaje de redes sociales.

Referencias

- Bird, S., Klein, E., & Loper, E. (2009). Natural Language Processing with Python. O'Reilly Media. <https://www.nltk.org/>
- Kaggle. (2019). Natural Language Processing with Disaster Tweets. <https://www.kaggle.com/competitions/nlp-getting-started>
- Loria, S. (2020). TextBlob: Simplified Text Processing. <https://textblob.readthedocs.io/>
- Mueller, A. (2020). WordCloud for Python. https://amueller.github.io/word_cloud/
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- Repositorio del laboratorio: <https://github.com/CindyGualim/Lab05-DataScience>